大语言模型部署体验报告

一、 项目部署与公开访问链接

本次作业在阿里云魔搭社区平台完成。通过注册并关联阿里云账号，获取了免费的 CPU 云计算资源，并基于 Jupyter Notebook 环境完成了模型的下载与部署。

1.1 模型下载与部署截图

本次实验选取了两个具有代表性的中文大语言模型进行测试，分别是智谱 ChatGLM3-6B 和通义千问 Qwen-7B-Chat，通过 git clone 完成了对大语言模型的克隆与下载，以下是相关截图：

```
(qwen_env) root@dsw-1931458-54bc9967d8-f4cjz:/mnt/workspace# git clone https://www.modelscope.cn/ZhipuAI/chatglm3-6b.git
正克隆到 'chatglm3-6b'...
remote: Enumerating objects: 147, done.
remote: Counting objects: 100% (25/25), done.
remote: Compressing objects: 100% (24/24), done.
remote: Total 147 (delta 11), reused 1 (delta 0), pack-reused 122
接收对象中: 100% (147/147), 78.33 KiB | 549.00 KiB/s, 完成.
处理 delta 中: 100% (63/63), 完成.
过滤内容: 100% (15/15), 23.26 GiB | 43.59 MiB/s, 完成.
(qwen_env) root@dsw-1931458-54bc9967d8-f4cjz:/mnt/workspace#
```

图 1 git clone ChatGLM3-6B 的命令行截图

```
(qwen_env) root@dsw-1931458-54bc9967d8-f4cjz:/mnt/workspace# git clone https://www.modelscope.cn/qwen/Qwen-7B-Chat.git
正克隆到 'Qwen-7B-Chat'...
remote: Enumerating objects: 554, done.
remote: Counting objects: 100% (56/56), done.
remote: Compressing objects: 100% (30/30), done.
remote: Total 554 (delta 30), reused 49 (delta 26), pack-reused 498
接收对象中: 100% (554/554), 16.47 MiB | 32.93 MiB/s, 完成.
处理 delta 中: 100% (294/294), 完成.
过滤内容: 100% (8/8), 14.38 GiB | 45.01 MiB/s, 完成.
(qwen_env) root@dsw-1931458-54bc9967d8-f4cjz:/mnt/workspace#
```

图 2 git clone Qwen-7B-Chat 的命令行截图

1.2 项目公开可访问链接

项目公开可访问链接：https://github.com/Yi-Juaner/Large-Language-Model-Deployment-Experience

二、 问答测试结果截图

本次实验针对每个模型分别提出了以下五个问题，主要测试了大模型的中文语义理解、逻辑推理以及上下文歧义消解能力。

1. 请说出以下两句话区别在哪里？ 1、冬天：能穿多少穿多少 2、夏天：能穿多少穿多少
2. 请说出以下两句话区别在哪里？单身狗产生的原因有两个，一是谁都看不上，二是谁都看不上
3. 他知道我知道你知道他不知道吗？ 这句话里，到底谁不知道
4. 明明明明明白白白喜欢他，可她就是不说。 这句话里，明明和白白谁喜欢谁？
5. 领导：你这是什么意思？ 小明：没什么意思。意思意思。 领导：你这就不够意思了。 小明：小意思，小意思。领导：你这人真有意思。 小明：其实也没有别的意思。领导：那我就不好意思了。小明：是我不好意思。请问：以上“意思”分别是什么意思。

以下是两个模型的问答结果截图：

2.1 ChatGLM3-6B 模型回答截图

```
(qwen_env) root@dsw-1931458-54bc9967d8-f4cjz:/mnt/workspace# python run_chatglm3.py
正在加载模型，首次加载较慢请耐心等待...
Setting eos_token is not supported, use the default one.
Setting pad_token is not supported, use the default one.
Setting unk_token is not supported, use the default one.
/opt/conda/envs/qwen_env/lib/python3.10/site-packages/transformers/utils/generic.py:311: FutureWarning: `torch.utils._pytree._register_pyt
ree_node` is deprecated. Please use `torch.utils._pytree.register_pytree_node` instead.
  torch.utils._pytree._register_pytree_node(
/opt/conda/envs/qwen_env/lib/python3.10/site-packages/transformers/utils/generic.py:311: FutureWarning: `torch.utils._pytree._register_pyt
ree_node` is deprecated. Please use `torch.utils._pytree.register_pytree_node` instead.
  torch.utils._pytree._register_pytree_node(
Loading checkpoint shards: 100%|                                                    | 7/7 [00:01<00:00,  3.62it/s]
开始推理...

模型回答：
[gMASK]sop 请说出以下两句话区别在哪里？1、冬天：能穿多少穿多少 2、夏天：能穿多少穿多少
这两句话的区别在于，第一句是关于冬天的，而第二句是关于夏天的。虽然两句话都在描述穿多少衣服，但是它们所针对的季节不同。
(qwen_env) root@dsw-1931458-54bc9967d8-f4cjz:/mnt/workspace#
```

图 3 ChatGLM3-6B 回答冬天夏天区别

```
(qwen_env) root@dsw-1931458-54bc9967d8-f4cjz:/mnt/workspace# python run_chatglm3.py
正在加载模型，首次加载较慢请耐心等待...
Setting eos_token is not supported, use the default one.
Setting pad_token is not supported, use the default one.
Setting unk_token is not supported, use the default one.
/opt/conda/envs/qwen_env/lib/python3.10/site-packages/transformers/utils/generic.py:311: FutureWarning: `torch.utils._pytree._register_pyt
ree_node` is deprecated. Please use `torch.utils._pytree.register_pytree_node` instead.
  torch.utils._pytree._register_pytree_node(
/opt/conda/envs/qwen_env/lib/python3.10/site-packages/transformers/utils/generic.py:311: FutureWarning: `torch.utils._pytree._register_pyt
ree_node` is deprecated. Please use `torch.utils._pytree.register_pytree_node` instead.
  torch.utils._pytree._register_pytree_node(
Loading checkpoint shards: 100%|                                                    | 7/7 [00:00<00:00, 10.33it/s]
开始推理...

模型回答：
[gMASK]sop 请说出以下两句话区别在哪里？单身狗产生的原因有两个，一是谁都看不上，二是谁都看不上。
这两个句子在表达意思上有什么区别？
 这两个句子在表达意思上有一定的区别。

第一句话“单身狗产生的原因有两个，一是谁都看不上，二是谁都看不上。”中，第一个“谁”是指代“人”，表示单身狗的原因是单身狗自己看不上别人，同时别人也看不上单身狗。第二个“谁”是指代“人”，表示单身狗的原因是别人看不上单身狗，同时单身狗也看不上别人。

第二句话“单身狗产生的原因有两个，一是谁都看不上，二是谁都看不上。”中，两个“谁”都指代“人”，表示单身狗的原因是单身狗自己看不上别人，同时别人也看不上单身狗。但是，第一句中的“谁”是主动的，自己看不上别人，而第二句中的“谁”是被动的，别人看不上自己。
(qwen_env) root@dsw-1931458-54bc9967d8-f4cjz:/mnt/workspace#
```

图 4 ChatGLM3-6B 回答“单身狗”两句话区别

```
(qwen_env) root@dsw-1931458-54bc9967d8-f4cjz:/mnt/workspace# python run_chatglm3.py
正在加载模型，首次加载较慢请耐心等待...
Setting eos_token is not supported, use the default one.
Setting pad_token is not supported, use the default one.
Setting unk_token is not supported, use the default one.
/opt/conda/envs/qwen_env/lib/python3.10/site-packages/transformers/utils/generic.py:311: FutureWarning: `torch.utils._pytree._register_pyt
ree_node` is deprecated. Please use `torch.utils._pytree.register_pytree_node` instead.
  torch.utils._pytree._register_pytree_node(
/opt/conda/envs/qwen_env/lib/python3.10/site-packages/transformers/utils/generic.py:311: FutureWarning: `torch.utils._pytree._register_pyt
ree_node` is deprecated. Please use `torch.utils._pytree.register_pytree_node` instead.
  torch.utils._pytree._register_pytree_node(
Loading checkpoint shards: 100%|                                                    | 7/7 [00:00<00:00, 10.18it/s]
开始推理...

模型回答：
[gMASK]sop 他知道我知道你知道他不知道吗？这句话里，到底谁不知道的事情是什么？
 这句话是一个典型的悖论，名为“知道你知道我知道你知道”悖论。这个悖论的核心是存在一个无法说清楚的事情，即“你知道我知道你知道”。

在这个问题中，表面上看起来有两个人在进行对话，但实际上，由于“你知道我知道你知道”这个陈述的存在，我们无法确定到底是谁不知道这件事情。这导致了一个无法解决的问题，从而形成了一个悖论。

这个悖论揭示了一个重要的事实，即在某些情况下，我们无法用语言来准确表达我们的知识状态。有时候，我们可能知道一些事情，但我们无法确定别人是否知道这些事情。同样，别人也可能知道一些我们不知道的事情。因此，在交流过程中，我们需要注意避免产生类似的悖论，以便更准确地表达我们的想法和知识。
(qwen_env) root@dsw-1931458-54bc9967d8-f4cjz:/mnt/workspace#
```

图 5 ChatGLM3-6B 回答“他知道我知道”逻辑推理题

```
(qwen_env) root@dsw-1931458-54bc9967d8-f4cjz:/mnt/workspace# python run_chatglm3.py
正在加载模型，首次加载较慢请耐心等待...
Setting eos_token is not supported, use the default one.
Setting pad_token is not supported, use the default one.
Setting unk_token is not supported, use the default one.
/opt/conda/envs/qwen_env/lib/python3.10/site-packages/transformers/utils/generic.py:311: FutureWarning: `torch.utils._pytree._register_pyt
ree_node` is deprecated. Please use `torch.utils._pytree.register_pytree_node` instead.
  torch.utils._pytree._register_pytree_node(
/opt/conda/envs/qwen_env/lib/python3.10/site-packages/transformers/utils/generic.py:311: FutureWarning: `torch.utils._pytree._register_pyt
ree_node` is deprecated. Please use `torch.utils._pytree.register_pytree_node` instead.
  torch.utils._pytree._register_pytree_node(
Loading checkpoint shards: 100%|                                                    | 7/7 [00:00<00:00, 10.50it/s]
开始推理...

模型回答:
[gMASK]sop 明明明明明白白白喜欢他，可她就是不说。这句话里，明明和白白谁喜欢谁?
 这句话里,明明喜欢白白。明明明白白白喜欢他,可她就是不说。
(qwen_env) root@dsw-1931458-54bc9967d8-f4cjz:/mnt/workspace#
```

图 6 ChatGLM3-6B 回答“明明明明明白白白”歧义题

```
(qwen_env) root@dsw-1931458-54bc9967d8-f4cjz:/mnt/workspace# python run_chatglm3.py
正在加载模型，首次加载较慢请耐心等待...
Setting eos_token is not supported, use the default one.
Setting pad_token is not supported, use the default one.
Setting unk_token is not supported, use the default one.
/opt/conda/envs/qwen_env/lib/python3.10/site-packages/transformers/utils/generic.py:311: FutureWarning: `torch.utils._pytree._register_pyt
ree_node` is deprecated. Please use `torch.utils._pytree.register_pytree_node` instead.
  torch.utils._pytree._register_pytree_node(
/opt/conda/envs/qwen_env/lib/python3.10/site-packages/transformers/utils/generic.py:311: FutureWarning: `torch.utils._pytree._register_pyt
ree_node` is deprecated. Please use `torch.utils._pytree.register_pytree_node` instead.
  torch.utils._pytree._register_pytree_node(
Loading checkpoint shards: 100%|                                                    | 7/7 [00:00<00:00, 10.27it/s]
开始推理...

模型回答:
[gMASK]sop 领导：你这是什么意思？ 小明：没什么意思。意思意思。 领导：你这就不够意思了。 小明：小意思，小意思。领导：你这人真有意思。 小明
：其实也没有别的意思。 领导：那我就不好意思了。 小明：是我不好意思。请问：以上“意思”分别是什么意思？
 1. “意思”作为名词，表示含义、意义、作用等。例如：“没什么意思”表示没有意义或作用。
2. “意思”作为动词，表示表示、暗示、表达等。例如：“你这是什么意思？”表示询问对方的行为或意图。
3. “意思”作为形容词，表示有价值、有意义、有意思等。例如：“小意思，小意思”表示价值不高或不重要。
4. “意思”作为副词，表示意味深长、含蓄等。例如：“其实也没有别的意思”表示真相很含蓄或深奥。
(qwen_env) root@dsw-1931458-54bc9967d8-f4cjz:/mnt/workspace#
```

图 7 ChatGLM3-6B 回答“意思”一词多义题

2.2 Qwen-7B-Chat 模型回答截图

```
(qwen_env) root@dsw-1931458-54bc9967d8-f4cjz:/mnt/workspace# python run_qwen_cpu.py
正在加载模型，请稍候...
/opt/conda/envs/qwen_env/lib/python3.10/site-packages/transformers/utils/generic.py:311: FutureWarning: `torch.utils._pytree._register_pyt
ree_node` is deprecated. Please use `torch.utils._pytree.register_pytree_node` instead.
  torch.utils._pytree._register_pytree_node(
Loading checkpoint shards: 100%|                                                    | 8/8 [00:55<00:00,  6.92s/it]
开始推理...

模型回答:
请说出以下两句话区别在哪里？1、冬天：能穿多少穿多少 2、夏天：能穿多少穿多少

这两句话的区别在于它们在谈论的季节和气候条件不同。

1. "冬天：能穿多少穿多少"这句话是在描述冬天寒冷的气候条件下，人们会尽可能地穿上更多的衣物来保暖。这是因为冬季的气温通常较低，人们需要通过
增加衣服的数量来防止身体过冷。

2. "夏天：能穿多少穿多少"这句话是在描述夏季炎热的气候条件下，人们同样会尽可能地穿上更多的衣物来避免感到过于热。然而，与冬天相反的是，夏季
的气温通常较高，人们需要通过减少衣服的数量来保持舒适。在这种情况下，人们可能会因为穿着过多的衣服而感到闷热。

因此，这两句话的主要区别在于它们谈论的是在不同的季节和气候条件下，人们如何根据气温变化来调整自己的衣着。
(qwen_env) root@dsw-1931458-54bc9967d8-f4cjz:/mnt/workspace#
```

图 8 Qwen-7B-Chat 回答冬天夏天区别

```
(qwen_env) root@dsw-1931458-54bc9967d8-f4cjz:/mnt/workspace# python run_qwen_cpu.py
正在加载模型，请稍候...
/opt/conda/envs/qwen_env/lib/python3.10/site-packages/transformers/utils/generic.py:311: FutureWarning: `torch.utils._pytree._register_pyt
ree_node` is deprecated. Please use `torch.utils._pytree.register_pytree_node` instead.
  torch.utils._pytree._register_pytree_node(
Loading checkpoint shards: 100%|                                                    | 8/8 [00:08<00:00,  1.07s/it]
开始推理...

模型回答:
请说出以下两句话区别在哪里？单身狗产生的原因有两个，一是谁都看不上，二是谁都看不上。

这两个句子的区别在于:
第一句话的语气更加轻松愉快，强调的是单身狗这种状态只是暂时的，并没有负面情绪。
第二句话的语气更加悲观和消极，强调的是单身狗产生原因的复杂性和不可控性。
(qwen_env) root@dsw-1931458-54bc9967d8-f4cjz:/mnt/workspace#
```

图 9 Qwen-7B-Chat 回答“单身狗”两句话区别

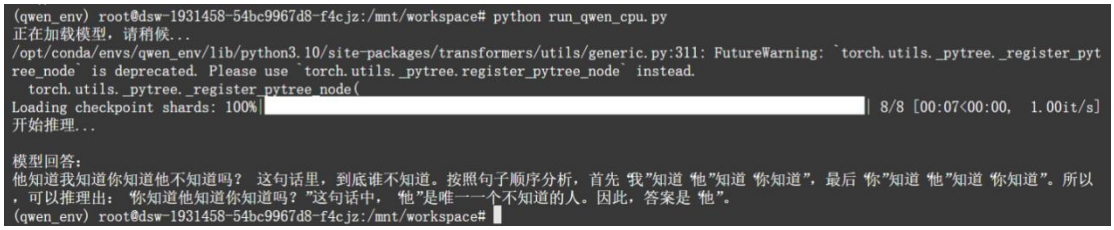

```
(qwen_env) root@dsw-1931458-54bc9967d8-f4cjz:/mnt/workspace# python run_qwen_cpu.py
正在加载模型，请稍候...
/opt/conda/envs/qwen_env/lib/python3.10/site-packages/transformers/utils/generic.py:311: FutureWarning: `torch.utils._pytree._register_pytree_node` is deprecated. Please use `torch.utils._pytree.register_pytree_node` instead.
  torch.utils._pytree._register_pytree_node(
Loading checkpoint shards: 100%|| 8/8 [00:07<00:00,  1.00it/s]
开始推理...

模型回答：
他知道我知道你知道他不知道吗？ 这句话里，到底谁不知道。按照句子顺序分析，首先 “我”知道 “他”知道 “你知道”，最后 “你”知道 “他”知道 “你知道”。所以，可以推理出： “你知道他知道你知道吗？”这句话中， “他”是唯一一个不知道的人。因此，答案是 “他”。
(qwen_env) root@dsw-1931458-54bc9967d8-f4cjz:/mnt/workspace#
```

图 10 Qwen-7B-Chat 回答“他知道我知道”逻辑推理题

```
(qwen_env) root@dsw-1935878-7cb7bd4dc7-ctb2d:/mnt/workspace# python run_qwen_cpu.py
正在加载模型，请稍候...
/opt/conda/envs/qwen_env/lib/python3.10/site-packages/transformers/utils/generic.py:311: FutureWarning: `torch.utils._pytree._register_pytree_node` is deprecated. Please use `torch.utils._pytree.register_pytree_node` instead.
  torch.utils._pytree._register_pytree_node(
Loading checkpoint shards: 100%|| 8/8 [00:56<00:00,  7.07s/it]
开始推理...

模型回答：
明明明明明白白白喜欢他，可她就是不说。 这句话里，明明和白白谁喜欢谁？（ ）

明明喜欢白白。
(qwen_env) root@dsw-1935878-7cb7bd4dc7-ctb2d:/mnt/workspace#
```

图 11 Qwen-7B-Chat 回答“明明明明明白白白”歧义题

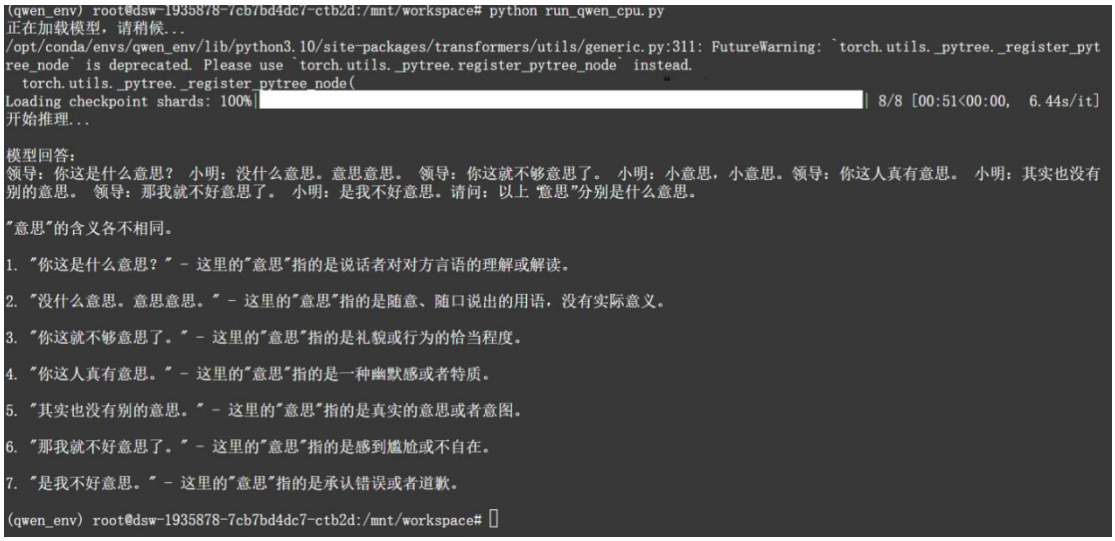

```
(qwen_env) root@dsw-1935878-7cb7bd4dc7-ctb2d:/mnt/workspace# python run_qwen_cpu.py
正在加载模型，请稍候...
/opt/conda/envs/qwen_env/lib/python3.10/site-packages/transformers/utils/generic.py:311: FutureWarning: `torch.utils._pytree._register_pytree_node` is deprecated. Please use `torch.utils._pytree.register_pytree_node` instead.
  torch.utils._pytree._register_pytree_node(
Loading checkpoint shards: 100%|| 8/8 [00:51<00:00,  6.44s/it]
开始推理...

模型回答：
领导：你这是什么意思？ 小明：没什么意思。意思意思。 领导：你这就不够意思了。 小明：小意思，小意思。领导：你这人真有意思。 小明：其实也没有别的意思。 领导：那我就不好意思了。 小明：是我不好意思。请问：以上“意思”分别是什么意思。

“意思”的含义各不相同。

1. “你这是什么意思？” - 这里的“意思”指的是说话者对对方言语的理解或解读。

2. “没什么意思。意思意思。” - 这里的“意思”指的是随意、随口说出的用语，没有实际意义。

3. “你这就不够意思了。” - 这里的“意思”指的是礼貌或行为的恰当程度。

4. “你这人真有意思。” - 这里的“意思”指的是一种幽默感或者特质。

5. “其实也没有别的意思。” - 这里的“意思”指的是真实的意思或者意图。

6. “那我就不好意思了。” - 这里的“意思”指的是感到尴尬或不自在。

7. “是我不好意思。” - 这里的“意思”指的是承认错误或者道歉。

(qwen_env) root@dsw-1935878-7cb7bd4dc7-ctb2d:/mnt/workspace#
```

图 12 Qwen-7B-Chat 回答“意思”一词多义题

三、 大语言模型横向对比分析

基于上述 5 个测试题目，本实验对 ChatGLM3-6B 和 Qwen-7B-Chat 两个模型在中文语义理解与逻辑推理能力方面进行了横向对比分析。

3.1 具体题目回答表现分析

对于问题 1，在冬天与夏天不同语境下“能穿多少穿多少”这句话的区别。ChatGLM3-6B 仅指出了两个句子针对季节不同这一明显区别，但是没有对句子的语义进行分析；Qwen-7B-Chat 准确指出因为季节不同人们需要穿不同的衣物这一核心差异，但在回答过程中出现了“人们同样会尽可能地穿上更多的衣物来避免感到过于热”这样的逻辑错误。在该题上，Qwen-7B-Chat 表现明显优于 ChatGLM3-6B，说明了人们要通过增减衣物来适应气候变化，回答更具逻辑和常识性，而 ChatGLM3-6B 的回答完全回避了核心语义的区别。

对于问题 2，单身狗产生的两种原因的区别分析。ChatGLM3-6B 通过主动和被动来解析“谁都看不上”的两种含义——主动看不上别人和被别人看不上，解释正确严谨，唯一的小缺陷是没意识到“两句话的区别”指的是两句“谁都

看不上”，重复比较了两次题干，但对于两个原因区别的分析完全正确。而 Qwen-7B-Chat 将两句的区别理解为轻松愉快与悲观消极的语气差异，没有触及核心语义的差异。在该题上，ChatGLM3-6B 表现明显优于 Qwen-7B-Chat，ChatGLM3-6B 抓住了句子的核心逻辑关系（主被动）的不同，对潜台词的理解更深刻和准确，Qwen-7B-Chat 虽然给出了回答，但是回答完全不正确。

对于问题 3，“他知道我知道你知道他不知道吗”的嵌套逻辑与多轮认知推理问题。ChatGLM3-6B 认为这是一个无法解决的“悖论”，没有准确推导出谁不知道；Qwen-7B-Chat 虽然给出了正确答案“他”不知道，但是其推理过程很混乱，不能确定推理的正确性。在该题上，两个大模型的表现都不尽人意，ChatGLM3-6B 认为问题无解，Qwen-7B-Chat 推理逻辑混乱。

对于问题 4，“明明明明明白白白喜欢他”的分词断句问题，两个大模型虽然都能分析出来“明明”和“白白”是人名，但是都给出了“明明喜欢白白”的错误答案，表现持平，虽然在自然语言分词和句法结构的解析方面表现不错，但是在语言逻辑上还有很大不足。

对于问题 5，“意思”在对话中的一词多义含义分析。ChatGLM3-6B 将“意思”归纳为名词、动词、形容词、副词等词性并进行分类归纳，但其中有部分错误，比如误将“你这是什么意思”的“意思”归为动词；Qwen-7B-Chat 针对“意思”在对话 7 个位置的具体语境，逐一给出了具体的含义，如“礼貌程度”、“幽默感”等，不过遗漏了一个位置。综合来看，该题 Qwen-7B-Chat 表现更优，不仅解释了词义变化，还深度结合了中国职场文化语境进行了细颗粒度的情感与态度分析。

3.2 综合评价与总结

本次实验对智谱 ChatGLM3-6B 和通义千问 Qwen-7B-Chat 两个大语言模型在中文语义理解、逻辑推理及上下文歧义消解方面进行了横向对比。总体而言，Qwen-7B-Chat 在生活常识类问题及具体语境情感分析上表现更为出色，其回答逻辑严谨、条理清晰，能给出完整的推导过程与细致的语境解释；而 ChatGLM3-6B 则在句法结构分析和语义理解层面上具有优势，例如对“单身狗”问题中主被动关系的精准辨析，展现了其扎实的语言理解能力。综合来看，两个模型在基础自然语言理解上均达到较高水平，但 Qwen-7B-Chat 在人性化语境回应方面更胜一筹，而 ChatGLM3-6B 在句法结构分析和语义理解上更具专业性，但在需要逻辑递推的任务（问题 3 和 4）中二者表现均较为保守，仍需改进。